第 3 部分（共 5 部分）· 解答

随机微积分，一步一步

第 3 部分：布朗运动与伊藤积分。
全部练习的完整解答



Rates with Bip

随机微积分，一步一步

第 3 部分：布朗运动与伊藤积分。练习解答

Rates with Bip

随机微积分，一步一步。第 3 部分：布朗运动与伊藤积分。练习解答。

© 2026 Rates with Bip。本书采用知识共享 署名-非商业性使用-禁止演绎 4.0 国际许可协议（CC BY-NC-ND 4.0）：你可以在注明作者 Rates with Bip 的前提下，为非商业目的原样复制和分享本书。许可协议：creativecommons.org/licenses/by-nc-nd/4.0。 配套笔记本以 MIT 许可协议免费提供：github.com/RatesWithBip/curriculum。

本书译自英文原版 Stochastic Calculus, Step by Step, Part 3: Solutions。代码、公式和数字与英文版完全相同。

全课程使用同一组数字：股价 $S_0 = 100$，行权价 $K = 105$，无风险利率 $r = 3\%$（连续复利），波动率 $\sigma = 20\%$，期限 $T = 1$ 年；第 3 部分取股票的期望收益率等于 r，即 $\mu = 3\%$。这些数字是为教学而虚构的，所有随机路径都用固定种子模拟。书中没有任何市场数据。

本册收录《随机微积分，一步一步》第 3 部分全部练习和自测题的完整解答。请先自己做每道练习，再看解答。

解答中的每个数字都由一个用断言自我检验的脚本计算；代码解答完整列出。

本书仅供学习之用，不构成任何金融、投资、法律或税务建议。

目录

如何使用这本解答 5

13. 布朗运动 6

14. 布朗路径的奇特性质 10

15. 伊藤积分 14

16. 伊藤引理 18

17. 几何布朗运动 22

18. 伊藤工具箱 26

如何使用这本解答

本册收录《随机微积分，一步一步》第 3 部分《布朗运动与伊藤积分》的完整解答：每道练习都完整解出，每一课末尾的自测题也给出答案。它应该在你自己尝试过每道题**之后**再读。

- **手算练习**（每课的前六道）完整解出。每个解答都从**思路**（打开局面的那一个想法）开始，然后分步骤展开，每一步都说明理由，最后以验证或解释结束。如果你卡住了，先只读思路，再自己试一试，然后才去读步骤。
- **编程练习**（每课的最后两道）给出完整的 Python 解答及其确切的输出。本册中的每个数字都由一个用断言自我检验的脚本生成，使用固定的随机种子，所以只要你用同样的种子，自己运行的结果应与书中显示的位数一致。
- **自测答案**很简短：一两句话，有数字的地方给出数字。

课程的数字始终不变：$S_0 = 100$，$K = 105$，$r = 3\%$（连续复利），$\sigma = 20\%$，$T = 1$ 年，第 3 部分中 $\mu = r$。

第 3 部分中几乎每个手算解答都用到三招之一：**拆分** $W_t = W_s + (W_t - W_s)$ 并利用独立性；应用**伊藤引理**，用 dt 代替 $(dW)^2$；或者**取期望**，这会消灭每一个 dW 项。如果你的答案不同，先检查常见的嫌疑：在该写标准差的地方写了方差，伊藤修正中漏了 $\tfrac{1}{2}$，在应为 $b^2\,dt$ 的地方写了 $(dX)^2 = dt$，以及忘了 f_t 项。

本册仅供学习之用，不构成金融建议。

第 13 课解答

布朗运动

练习 13.1 至 13.8 以及第 13 课自测题的解答。

练习 13.1

思路。 位置是 nt 个独立步子之和；均值相加，方差也相加。

第 1 步：一步。 δX_i，其中 $\delta = 1/\sqrt{n}$，$X_i = \pm 1$：均值为 $\delta\,(\tfrac{1}{2} - \tfrac{1}{2}) = 0$，而由于总有 $(\delta X_i)^2 = \delta^2 = 1/n$，方差为 $1/n$。

第 2 步：把 nt 步加起来。 均值为 0；方差为 $nt \times 1/n = t$（步子独立：方差相加）。

为什么是 $1/\sqrt{n}$。 步长为 δ 时，时刻 t 的方差为 $nt\delta^2$。只有当 $\delta^2 = 1/n$ 时，它才对每个 n 都保持为 t。若 $\delta = 1/n$，方差将是 $t/n \to 0$：游走会缩成 0 处的一条平线，不剩任何随机性。若 $\delta = 1$，方差将是 $nt \to \infty$。

练习 13.2

思路。 把较晚的值拆成较早的值加上一个独立的移动。

协方差。 对 $s \le t$：$W_t = W_s + (W_t - W_s)$，所以 $E[W_s W_t] = E[W_s^2] + E[W_s]E[W_t - W_s] = s + 0$。两个均值都是 0，所以 $\mathrm{Cov}(W_s, W_t) = s = \min(s,t)$。

$\mathrm{Var}(W_1 + W_2)$。 $= \mathrm{Var}(W_1) + \mathrm{Var}(W_2) + 2\mathrm{Cov}(W_1, W_2) = 1 + 2 + 2\min(1,2) = 5$。

W_1 与 W_4 的相关系数。 $\dfrac{\min(1,4)}{\sqrt{1}\,\sqrt{4}} = \dfrac{1}{2} = 0.5$。

练习 13.3

思路。 第一个事件关乎两次独立的移动；第二个则不然。

第一个概率。 W_1 和 $W_2 - W_1$ 相互独立，都是均值为 0 的正态变量，所以各以概率 $\frac{1}{2}$ 为正：

$$P(W_1 > 0,\ W_2 - W_1 > 0) = \tfrac{1}{2} \times \tfrac{1}{2} = 0.25.$$

为什么第二个更大。 $\{W_1 > 0, W_2 > 0\}$ 包含第一个事件中的每一条路径（如果 $W_1 > 0$ 且路径随后上升，则 $W_2 > 0$），**还**包含那些在 $[1,2]$ 上下降、但降幅小于 W_1 因而保持为正的路径。所以它更大：$\frac{3}{8} = 0.375$。W_1 和 W_2 的值正相关（相关系数 $1/\sqrt{2}$），所以“两者都为正”比独立变量时更可能发生。（$\frac{3}{8}$ 来自两个相关正态变量的一个标准公式 $\frac{1}{4} + \arcsin(\rho)/(2\pi)$，其中 $\rho = 1/\sqrt{2}$，$\arcsin\rho = \pi/4$。）

练习 13.4

思路。 B 的每条性质都由 W 的同一条性质推出，只是时间被拉伸了 c 倍。

1. **起点**。 $B_0 = W_0/\sqrt{c} = 0$。
2. **独立增量**。 对 $t_0 < t_1 < \cdots < t_k$，增量 $B_{t_j} - B_{t_{j-1}} = (W_{ct_j} - W_{ct_{j-1}})/\sqrt{c}$ 是 W 在互不重叠的区间 $[ct_{j-1}, ct_j]$ 上的增量，因此相互独立；除以常数不改变独立性。
3. **正态增量**。 $W_{ct} - W_{cs} \sim N(0, c(t-s))$，所以除以 $\sqrt{c}$ 后方差为 $c(t-s)/c = t - s$：$B_t - B_s \sim N(0, t-s)$。
4. **连续性**。 $t \mapsto W_{ct}/\sqrt{c}$ 是连续函数与一个拉伸的复合：连续。

所以 B 是布朗运动。

练习 13.5

思路。 拆分、平方，再逐项取条件期望。

第 1 步。 令 $D = W_t - W_s$：$W_t^2 = W_s^2 + 2W_sD + D^2$。

第 2 步。 给定 $\mathcal{F}_s$：W_s^2 已知；$E[W_sD \mid \mathcal{F}_s] = W_sE[D] = 0$（先提出已知量，再用独立性）；$E[D^2 \mid \mathcal{F}_s] = E[D^2] = t - s$。

第 3 步。 $E[W_t^2 \mid \mathcal{F}_s] = W_s^2 + t - s$，所以 $E[W_t^2 - t \mid \mathcal{F}_s] = W_s^2 - s$。$\surd$

练习 13.6

思路。 拆开指数；已知的部分提出来，独立的部分有已知的平均值。

第 1 步。 $Z_t = e^{\sigma W_s - \frac{1}{2}\sigma^2 t}\, e^{\sigma D}$，其中 $D = W_t - W_s \sim N(0, t-s)$。

第 2 步。 $E[e^{\sigma D} \mid \mathcal{F}_s] = E[e^{\sigma D}] = e^{\sigma^2 (t-s)/2}$（第 4 课，取 $u = \sigma$，$v = t - s$）。

第 3 步。 $E[Z_t \mid \mathcal{F}_s] = e^{\sigma W_s - \frac{1}{2}\sigma^2 t + \frac{1}{2}\sigma^2 (t-s)} = e^{\sigma W_s - \frac{1}{2}\sigma^2 s} = Z_s$。$\surd$

股票。 $e^{-rt} S_t = S_0 e^{(r - \frac{1}{2}\sigma^2)t - rt + \sigma W_t} = S_0 e^{\sigma W_t - \frac{1}{2}\sigma^2 t} = S_0 Z_t$，一个常数乘以一个鞅，所以是鞅。取 $\sigma = 20\%$，修正量为每年 $\frac{1}{2}\sigma^2 = 0.02$。

练习 13.7

时刻 1 的缩放随机游走，与正态分布对比。

```
import math

import numpy as np

N = lambda x: 0.5 * (1 + math.erf(x / math.sqrt(2)))
rng = np.random.default_rng(137)
for n in (10, 100, 10_000):
    heads = rng.binomial(n, 0.5, 200_000)         # how many of the n steps went up
    W1 = (2 * heads - n) / math.sqrt(n)           # the walker at time 1
    print(f"n = {n:6d}: P(W1 <= 1) = {np.mean(W1 <= 1):.4f}   (N(1) = {N(1):.4f}); "
          f"possible values spaced {2 / math.sqrt(n):.3f} apart")
```

它的输出。

```
n =     10: P(W1 <= 1) = 0.8295   (N(1) = 0.8413); possible values spaced 0.632 apart
n =    100: P(W1 <= 1) = 0.8648   (N(1) = 0.8413); possible values spaced 0.200 apart
n =  10000: P(W1 <= 1) = 0.8440   (N(1) = 0.8413); possible values spaced 0.020 apart
```

为什么 n 小时有偏差。 时刻 1 的游走只能取值 $(2k - n)/\sqrt{n}$，间距为 $2/\sqrt{n}$：对 $n = 10$，间距为 0.632。它的分布函数是一道阶梯，而 $P(W \le 1)$ 取决于台阶相对于 1 落在哪里。对 $n = 100$，有一个可能的值恰好是 1（55 次正面），它带有约 0.05 的概率，这就是那一行偏高的原因。随着 n 增大，台阶变细，答案趋近 $N(1) = 0.8413$。

练习 13.8

模拟路径上的协方差与指数鞅。

```
rng = np.random.default_rng(138)
paths, steps, T, sigma = 50_000, 400, 2.0, 0.2
dt = T / steps
W = np.concatenate([np.zeros((paths, 1)), np.cumsum(rng.normal(0, math.sqrt(dt), (paths,
steps)), axis=1)], axis=1)
at = lambda t: W[:, int(round(t / dt))]
for s, t in ((0.5, 1.0), (0.5, 2.0), (1.0, 1.5), (1.5, 2.0)):
    print(f"Cov(W_{s}, W_{t}) = {np.mean(at(s) * at(t)):.4f}   min(s, t) = {min(s, t)}")
for t in (0.5, 1.0, 2.0):
    Z = np.exp(sigma * at(t) - 0.5 * sigma**2 * t)
    print(f"E[Z_{t}] = {Z.mean():.4f}")
```

它的输出。

```
Cov(W_0.5, W_1.0) = 0.4968   min(s, t) = 0.5
Cov(W_0.5, W_2.0) = 0.4992   min(s, t) = 0.5
Cov(W_1.0, W_1.5) = 0.9898   min(s, t) = 1.0
Cov(W_1.5, W_2.0) = 1.4811   min(s, t) = 1.5
E[Z_0.5] = 1.0012
E[Z_1.0] = 1.0014
E[Z_2.0] = 1.0028
```

读输出。 每个协方差与 $\min(s,t)$ 的差都在 0.02 左右以内，这是 50,000 条路径的抽样噪声大小。$E[Z_t]$ 在三个时刻都保持为 1：指数鞅的期望不变。

自测

1. 方差 0.25，标准差 0.5。

2. 为了使时刻 t 的方差对每个 n 都恰好是 t：步子更小会使游走消失，更大则会使它爆炸。

3. 只有 W_t。修正后的版本：$W_t^2 - t$ 和 $e^{W_t - t/2}$。

第 14 课解答

布朗路径的奇特性质

练习 14.1 至 14.8 以及第 14 课自测题的解答。

练习 14.1

思路。 把正态变量除以常数，它的标准差也按比例缩放。

第 1 步。 $W_{t+h} - W_t \sim N(0, h)$，所以 $Q_h = (W_{t+h} - W_t)/h \sim N(0, h/h^2) = N(0, 1/h)$。

第 2 步。 $Q_h = Z/\sqrt{h}$，Z 为标准正态变量，所以 $P(|Q_h| > 1) = P(|Z| > \sqrt{h}) = 2\big(1 - N(\sqrt{h})\big)$。

- $h = 0.01$：$2(1 - N(0.1)) = 0.9203$。
- $h = 0.0001$：$2(1 - N(0.01)) = 0.9920$。

解读。 随着步长缩小，斜率超过 1（或任何界）的可能性越来越大：它不会稳定下来。

练习 14.2

思路。 每次移动是 $\sqrt{\Delta t}$ 乘以一个标准正态变量，而 $E|Z| = \sqrt{2/\pi}$。

$$E\sum_{i=1}^{n} |\Delta W_i| = n\sqrt{\Delta t}\sqrt{\frac{2}{\pi}} = n\sqrt{\frac{T}{n}}\sqrt{\frac{2}{\pi}} = \sqrt{\frac{2nT}{\pi}}.$$

取 $T = 1$：$n = 100$ 时为 7.98，$n = 10{,}000$ 时为 79.79，$n = 1{,}000{,}000$ 时为 797.9。n 每增加一百倍，路径就长十倍。

练习 14.3

思路。 均值趋于 T，方差趋于 0，再用切比雪夫不等式。

均值。 $E[(\Delta W_i)^2] = \Delta t$，所以 $E[Q_n] = n\Delta t = T$。

方差。 $(\Delta W_i)^2 = \Delta t\, Z_i^2$，而 $\mathrm{Var}(Z^2) = E[Z^4] - (E[Z^2])^2 = 3 - 1 = 2$。所以每个平方的方差为 $2\Delta t^2$；它们相互独立，所以 $\mathrm{Var}(Q_n) = 2n\Delta t^2 = 2T^2/n$。

收敛。 由切比雪夫不等式（第 6 课），对任意 $\varepsilon > 0$：

$$P(|Q_n - T| \geq \varepsilon) \leq \frac{2T^2}{n\varepsilon^2} \to 0.$$

练习 14.4

思路。 数一数量级：每一项都很小，而项数又不够多。

$\sum \Delta W_i\, \Delta t$。 均值为 $\Delta t \sum E[\Delta W_i] = 0$。方差为 $\Delta t^2 \sum \mathrm{Var}(\Delta W_i) = \Delta t^2 \cdot n\Delta t = T\Delta t^2 \to 0$。均值为 0，方差趋于 0：它趋于 0。

$\sum \Delta t^2 = n\Delta t^2 = T\Delta t \to 0$。

为什么 $\sum(\Delta W_i)^2$ 不同。 每一项的量级是 Δt（而不是 $\Delta t^{3/2}$ 或 Δt^2），共有 $T/\Delta t$ 项：总和的量级是 1。在另外两个和中，每一项的量级都高于 Δt，所以 $T/\Delta t$ 个这样的项加起来仍然趋于零。

练习 14.5

思路。 光滑部分毫无贡献；每单位 dW 贡献 dt，按其系数的平方缩放。

(a) $f(t) = 100e^{0.03t}$ 是光滑的（它的斜率至多为 $3e^{0.03T}$），所以它的二次变差为 0。

(b) $\sum(\sigma\Delta W_i)^2 = \sigma^2 \sum(\Delta W_i)^2 \to \sigma^2 T$。

(c) $\Delta \ln S_i = (r - \frac{1}{2}\sigma^2)\Delta t + \sigma\Delta W_i$。平方：$(r - \frac{1}{2}\sigma^2)^2\Delta t^2 + 2(r - \frac{1}{2}\sigma^2)\sigma\Delta t\,\Delta W_i + \sigma^2(\Delta W_i)^2$。由练习 14.4，前两个和消失；第三个趋于 $\sigma^2 T$。所以 $[\ln S]_T = \sigma^2 T$：取 $\sigma = 20\%$、$T = 1$，为 0.04。漂移无关紧要。

练习 14.6

思路。 B 是独立正态部分之和；然后把移动的乘积展开。

B 是布朗运动。 $B_0 = 0$。它在 $[s, t]$ 上的增量是 $\rho(W_t - W_s) + \sqrt{1-\rho^2}(W'_t - W'_s)$：方差分别为 $\rho^2(t-s)$ 和 $(1-\rho^2)(t-s)$ 的独立正态变量，所以是方差为 $t - s$ 的正态变量。不相交区间上的增量涉及 W 和 W' 的不同部分，所以相互独立。而且 B 是连续

的。

交叉和。 $\Delta W_i\,\Delta B_i = \rho(\Delta W_i)^2 + \sqrt{1-\rho^2}\,\Delta W_i\,\Delta W_i'$。第一部分的和为 ρT（第 14 课）。第二部分的均值为 0（ΔW_i 和 $\Delta W_i'$ 独立，均值都为 0），方差为 $(1-\rho^2)\sum \Delta t^2 = (1-\rho^2)T\Delta t \to 0$。所以 $\sum \Delta W_i\,\Delta B_i \to \rho T$：$dW\,dB = \rho\,dt$。

练习 14.7

一年每日对数收益率的已实现方差，重复 10,000 次。

```
import numpy as np

S0, r, sigma, T, n = 100.0, 0.03, 0.20, 1.0, 252
dt = T / n
rng = np.random.default_rng(147)
dW = rng.normal(0, math.sqrt(dt), (10_000, n))
dlogS = (r - 0.5 * sigma**2) * dt + sigma * dW          # daily log returns
rv = (dlogS**2).sum(axis=1)                             # realised variance, one per year
print(f"realised variance: mean {rv.mean():.5f}, sd {rv.std():.5f}")
print(f"sigma^2 T = {sigma**2 * T:.5f}; theory sd sigma^2 sqrt(2T dt) = {sigma**2 *
math.sqrt(2 * T * dt):.5f}")
print(f"realised volatility sqrt(rv): mean {np.sqrt(rv).mean():.4f}")
```

它的输出。

```
realised variance: mean 0.03999, sd 0.00358
sigma^2 T = 0.04000; theory sd sigma^2 sqrt(2T dt) = 0.00356
realised volatility sqrt(rv): mean 0.1998
```

读输出。 已实现方差的平均为 $\sigma^2 T = 0.04$，标准差为 0.00358，与 $\sigma^2\sqrt{2T\Delta t}$ 相符（练习 14.3，每单位时间方差为 σ^2）。所以一年的每日价格能把方差测量到约 9% 以内，把波动率测量到约 4.5% 以内。用日内数据，误差会进一步缩小：理论上可以缩小到 0。

练习 14.8

一条路径越切越细时的一阶变差与二次变差。

```
rng = np.random.default_rng(148)
fine = 2**20
W = np.concatenate([[0], np.cumsum(rng.normal(0, math.sqrt(1 / fine), fine))])
print("   steps   first variation   quadratic variation")
for k in range(4, 21, 2):
    incr = np.diff(W[:: fine // 2**k])                  # the same path, cut into 2^k steps
    print(f"{2**k:8d}   {np.abs(incr).sum():15.2f}   {(incr**2).sum():19.4f}")
```

它的输出。

```
   steps   first variation   quadratic variation
      16              3.89                1.6096
      64              6.30                1.1041
     256             12.73                0.9775
    1024             25.40                0.9939
    4096             51.04                1.0142
   16384            101.95                0.9914
   65536            203.30                0.9934
  262144            408.54                0.9983
 1048576            816.64                0.9992
```

读输出。 步数每增加到四倍，一阶变差就翻倍（它像 $\sqrt{n}$ 那样增长），而二次变差稳定在 1 附近，波动越来越小。画在对数轴上，前者是一条斜率为 ½ 的直线，后者是一条位于 T 的水平线。

自测

1. 在步长 h 上的移动大小约为 $\sqrt{h}$，所以斜率的大小约为 $\sqrt{h}/h = 1/\sqrt{h}$，当 $h \to 0$ 时它无限增长。

2. $\sigma^2 T = 0.04$。

3. 1。无论 W_1 是多少，二次变差在每条路径上都是 $T = 1$。

第 15 课解答

伊藤积分

练习 15.1 至 15.8 以及第 15 课自测题的解答。

练习 15.1

思路。 把下一个值的平方展开；差的和可以望远镜式相消。

第 1 步。 对每一步，$W_{t_{i+1}}^2 = (W_{t_i} + \Delta W_i)^2 = W_{t_i}^2 + 2W_{t_i}\Delta W_i + (\Delta W_i)^2$，所以

$$W_{t_i}\Delta W_i = \tfrac{1}{2}\big(W_{t_{i+1}}^2 - W_{t_i}^2\big) - \tfrac{1}{2}(\Delta W_i)^2.$$

第 2 步：对 i 求和。 第一个括号望远镜式相消：$\sum_i (W_{t_{i+1}}^2 - W_{t_i}^2) = W_T^2 - W_0^2 = W_T^2$。所以

$$\sum_i W_{t_i}\Delta W_i = \tfrac{1}{2}W_T^2 - \tfrac{1}{2}\sum_i (\Delta W_i)^2,$$

对任意划分都精确成立。

第 3 步：极限。 $\sum(\Delta W_i)^2 \to T$（第 14 课），所以左端点和趋于 $\tfrac{1}{2}W_T^2 - \tfrac{1}{2}T$。

练习 15.2

思路。 右端点和 = 左端点和 + 二次变差。

$$\sum W_{t_{i+1}}\Delta W_i = \sum W_{t_i}\Delta W_i + \sum(\Delta W_i)^2 \to \big(\tfrac{1}{2}W_T^2 - \tfrac{1}{2}T\big) + T = \tfrac{1}{2}W_T^2 + \tfrac{1}{2}T。$$

为什么没有交易者能赚到它。 它在 $[t_i, t_{i+1}]$ 期间持有 $W_{t_{i+1}}$ 股：股数取决于这一步**结束**时的价格，而建仓时这个价格还不知道。能做到这一点的交易者会事先知道每一次移动，能从一场公平游戏中赚到 $E[\cdot] = T > 0$：一种建立在未卜先知之上的套利。

练习 15.3

思路。 均值来自鞅性质，方差来自等距性，然后直接验证。

均值。 $E\int_0^T W\,dW = 0$（鞅，W 是适应的）。

方差。 由等距性，$E\big[(\int_0^T W\,dW)^2\big] = E\int_0^T W_t^2\,dt = \int_0^T E[W_t^2]\,dt = \int_0^T t\,dt = \frac{1}{2}T^2$。（交换 E 与 $\int dt$ 是允许的：两者都是求和。）均值为 0，所以这就是方差。

直接验证。 $\int_0^T W\,dW = \frac{1}{2}(W_T^2 - T)$：

- 均值 $\frac{1}{2}(E[W_T^2] - T) = \frac{1}{2}(T - T) = 0$ ✓；
- 方差 $\frac{1}{4}\mathrm{Var}(W_T^2) = \frac{1}{4}(E[W_T^4] - (E[W_T^2])^2) = \frac{1}{4}(3T^2 - T^2) = \frac{1}{2}T^2$ ✓。

练习 15.4

思路。 确定性的被积函数给出独立正态变量之和。

第 1 步。 $\sum t_i \Delta W_i$ 是独立的 $N(0, t_i^2\Delta t)$ 变量之和，所以它是正态的，均值为 0，方差为 $\sum t_i^2 \Delta t \to \int_0^1 t^2\,dt = \frac{1}{3}$。方差收敛的正态变量的极限是正态的：$J \sim N(0, \frac{1}{3})$。

第 2 步。 $P(J > 0.5) = P\big(Z > 0.5/\sqrt{1/3}\big) = 1 - N(0.8660) = 0.1932$。

练习 15.5

思路。 两者都是普通函数对同一个 dW 的积分。

$W_1 = \int_0^1 1\,dW_t$，$J = \int_0^1 t\,dW_t$，均值都为 0。所以

$$\mathrm{Cov}(W_1, J) = E\Big[\int_0^1 1\,dW \int_0^1 t\,dW\Big] = \int_0^1 1\cdot t\,dt = \tfrac{1}{2}.$$

为什么乘积公式成立。 对 $f+g$ 和 $f-g$ 分别应用等距性，再相减：$E[(\int (f+g)dW)^2] - E[(\int (f-g)dW)^2] = 4E[\int f\,dW \int g\,dW]$，而右边给出 $\int (f+g)^2 - \int (f-g)^2 = 4\int fg$。

在离散和中验证。 $E\big[\sum_i \Delta W_i \sum_j t_j \Delta W_j\big] = \sum_i t_i E[(\Delta W_i)^2] = \sum t_i \Delta t \to \frac{1}{2}$（$i \neq j$ 的交叉项均值为 0）。

练习 15.6

思路。 把离散的乘积法则在各步上求和；它会望远镜式相消。

第 1 步：验证恒等式。 $t_{i+1}W_{t_{i+1}} - t_i W_{t_i} = t_i(W_{t_{i+1}} - W_{t_i}) + (t_{i+1} - t_i)W_{t_{i+1}} = t_i \Delta W_i + W_{t_{i+1}}\Delta t$。（加上再减去 $t_i W_{t_{i+1}}$。）

第 2 步：对 i 求和。 左边望远镜式相消为 $TW_T - 0$：

$$TW_T = \sum_i t_i \Delta W_i + \sum_i W_{t_{i+1}} \Delta t.$$

第 3 步：极限。 第一个和趋于 $\int_0^T t\, dW_t$（按要求用左端点）。第二个是普通积分 $\int_0^T W_t\, dt$ 的黎曼和（对连续路径，这里端点无关紧要：其中没有 dW）。所以 $\int_0^T t\, dW_t = TW_T - \int_0^T W_t\, dt$。

注。 没有出现多余的项：t 是光滑的，所以乘积的“交叉项” $\Delta t\, \Delta W$ 求和为 0。第 18 课的乘积法则说的是同一件事。

练习 15.7

一条路径上 ∫W dW 的左端点、右端点和平均的和。

```
import numpy as np

rng = np.random.default_rng(157)
fine = 2**18
W = np.concatenate([[0], np.cumsum(rng.normal(0, math.sqrt(1 / fine), fine))])
W1 = W[-1]
print(f"W_1 = {W1:.4f}: (W^2 - 1)/2 = {(W1**2 - 1) / 2:.4f}, (W^2 + 1)/2 = {(W1**2 + 1) /
2:.4f}, W^2/2 = {W1**2 / 2:.4f}")
print("   steps      left     right    middle")
for k in range(4, 19, 2):
    Wk = W[:: fine // 2**k]                  # the same path on 2^k steps
    d = np.diff(Wk)
    left, right = (Wk[:-1] * d).sum(), (Wk[1:] * d).sum()
    print(f"{2**k:8d}  {left:8.4f}  {right:8.4f}  {(left + right) / 2:8.4f}")
```

它的输出。

```
W_1 = 1.0243: (W^2 - 1)/2 = 0.0246, (W^2 + 1)/2 = 1.0246, W^2/2 = 0.5246
   steps      left     right    middle
      16    0.1732    0.8760    0.5246
      64   -0.0039    1.0531    0.5246
     256    0.0768    0.9724    0.5246
    1024    0.0470    1.0022    0.5246
    4096    0.0370    1.0122    0.5246
   16384    0.0212    1.0280    0.5246
   65536    0.0267    1.0225    0.5246
  262144    0.0252    1.0241    0.5246
```

读输出。 在这条路径上 $W_1 = 1.0243$。平均那一列对每个 n 都恰好是 $\frac{1}{2}W_1^2$（它望远镜式相消）。左端点和右端点两列在 n 小时游移不定，随着步长缩小分别逼近 $\frac{1}{2}(W_1^2 - 1)$ 和 $\frac{1}{2}(W_1^2 + 1)$，在极限中总是相差 1。

练习 15.8

两个伊藤积分各 100,000 个样本。

```
paths, steps = 100_000, 500
dt = 1 / steps
t = np.arange(steps) * dt                       # left endpoints
J = np.zeros(paths); I = np.zeros(paths); W = np.zeros(paths)
for k in range(steps):                          # step through time to keep memory small
    dW = rng.normal(0, math.sqrt(dt), paths)
    J += t[k] * dW
    I += W * dW                                 # W is still the left-endpoint value here
    W += dW
print(f"int t dW: mean {J.mean():+.4f}, variance {J.var():.4f} (theory 1/3 = {1 / 3:.4f}),
P(< 0) = {np.mean(J < 0):.4f}")
print(f"int W dW: mean {I.mean():+.4f}, variance {I.var():.4f} (theory 1/2), P(< 0) =
{np.mean(I < 0):.4f} "
      f"(theory P(W_1^2 < 1) = {2 * Ncdf(1) - 1:.4f})")
```

它的输出。

```
int t dW: mean +0.0001, variance 0.3344 (theory 1/3 = 0.3333), P(< 0) = 0.4996
int W dW: mean +0.0020, variance 0.5048 (theory 1/2), P(< 0) = 0.6812 (theory P(W_1^2 < 1) =
0.6827)
```

读输出。 $\int t\,dW$ 是对称的（正态），所以有一半时间为负；它的方差约为 $\frac{1}{3}$。$\int W\,dW = \frac{1}{2}(W_1^2 - 1)$ 是偏斜的：只要 $|W_1| < 1$ 就为负，其概率为 0.6827，但它有一条长长的右尾，把均值拉回到 0。均值相同，形状却大不相同。

自测

1. 因为被积函数是一个交易持仓，在它赚取收益的那次移动之前就已选定。左端点使它保持适应，而这正是积分成为鞅的原因。

2. 均值为 0，方差为 $\frac{1}{2}$。

3. $\int_0^2 3\,dW_t = 3W_2 \sim N(0, 9 \times 2) = N(0, 18)$。

第 16 课解答

伊藤引理

练习 16.1 至 16.8 以及第 16 课自测题的解答。

练习 16.1

思路。 应用 $df = f'\,dW + \frac{1}{2}f''\,dt$；取期望时，$dW$ 部分消失。

W^3。 $f' = 3x^2$，$f'' = 6x$：$d(W^3) = 3W^2\,dW + 3W\,dt$。 *验证：* $E[W_T^3] - 0 = 0 + \int_0^T 3E[W_t]\,dt = 0$，而确实 $E[W_T^3] = 0$（对称分布的奇数阶矩）。

e^W。 $f' = f'' = e^x$：$d(e^W) = e^W\,dW + \frac{1}{2}e^W\,dt$。 *验证：* $E[e^{W_T}] - 1 = \int_0^T \frac{1}{2}E[e^{W_t}]\,dt$。由 $E[e^{W_t}] = e^{t/2}$（第 4 课），右边为 $\int_0^T \frac{1}{2}e^{t/2}\,dt = e^{T/2} - 1$。$\surd$

练习 16.2

思路。 用二元形式，取 $f(t, x) = tx$，输入 $X = W$（$a = 0$，$b = 1$）。

$f_t = x$，$f_x = t$，$f_{xx} = 0$，所以

$$d(tW_t) = (W_t + 0 + \tfrac{1}{2}\cdot 1 \cdot 0)\,dt + t\,dW_t = W_t\,dt + t\,dW_t.$$

普通微积分（乘积法则）给出同样的结果 $d(tW) = W\,dt + t\,dW$：**这里没有伊藤修正**，因为 f 在 x 方向上是直线（$f_{xx} = 0$）。修正需要曲率。

练习 16.3

思路。 用二元伊藤引理，取 $f(t, w) = e^{\sigma w - \frac{1}{2}\sigma^2 t}$。

$f_t = -\frac{1}{2}\sigma^2 f$，$f_w = \sigma f$，$f_{ww} = \sigma^2 f$。以 W 为输入：

$$dZ = \left(-\tfrac{1}{2}\sigma^2 Z + \tfrac{1}{2}\sigma^2 Z\right)dt + \sigma Z\,dW = \sigma Z\,dW.$$

时间导数与伊藤修正恰好抵消：没有 dt 项。

练习 16.4

思路。对 W^6 用伊藤引理，把六阶矩与四阶矩联系起来。

第 1 步。$f = x^6$：$f' = 6x^5$，$f'' = 30x^4$，所以 $d(W^6) = 6W^5\,dW + 15W^4\,dt$。

第 2 步。取期望：$E[W_T^6] = \int_0^T 15E[W_t^4]\,dt = \int_0^T 15 \cdot 3t^2\,dt = 15T^3$。

（第 4 课的 $E[Z^6] = 15$ 是 $T = 1$ 的情形。）

练习 16.5

思路。对 $f(x) = x^2$ 用一般输入的伊藤引理；然后取平均并积分。

第 1 步。$f_x = 2x$，$f_{xx} = 2$：

$$d(X^2) = (2aX + \tfrac{1}{2}b^2 \cdot 2)\,dt + 2bX\,dW = (2aX + b^2)\,dt + 2bX\,dW.$$

第 2 步。取平均：$\frac{d}{dt}E[X_t^2] = 2aE[X_t] + b^2 = 2a \cdot at + b^2$（因为 $E[X_t] = at$）。

第 3 步。从 0 积分，$E[X_0^2] = 0$：$E[X_T^2] = a^2T^2 + b^2T$。

验证。$X_T = aT + bW_T$ 的均值为 aT，方差为 b^2T，所以 $E[X_T^2] = (aT)^2 + b^2T$。√ 用本课的 $a = 0.03$、$b = 0.2$、$T = 1$：0.0409。

练习 16.6

思路。余弦的二阶导数是它自身的相反数，所以它的平均满足 $m' = -\frac{1}{2}m$。

第 1 步。$f = \cos x$：$f' = -\sin x$，$f'' = -\cos x$。所以 $dY = -\sin W\,dW - \frac{1}{2}\cos W\,dt$。

第 2 步。取平均：$m(t) = E[\cos W_t]$ 满足 $m'(t) = -\frac{1}{2}m(t)$，$m(0) = \cos 0 = 1$。

第 3 步。求解（第 2 课）：$m(t) = e^{-t/2}$。在 $t = 1$ 时：0.6065。

解读。平均而言，一个逐渐散开的随机点的余弦会衰减：散得越开，它的正值和负值就抵消得越多。

练习 16.7

在一条路径上对 x^3 验证伊藤引理。

```
import numpy as np

rng = np.random.default_rng(167)
fine = 2**18
W = np.concatenate([[0], np.cumsum(rng.normal(0, math.sqrt(1 / fine), fine))])
print(f"W_1^3 = {W[-1] ** 3:.5f}")
print("   steps     sum 3W^2 dW    + sum 3W dt    total")
for k in range(6, 19, 2):
    n = 2**k
    Wn = W[:: fine // n]
    first = (3 * Wn[:-1] ** 2 * np.diff(Wn)).sum()
    ito = (3 * Wn[:-1] * (1 / n)).sum()
    print(f"{n:8d}   {first:12.5f}   {ito:12.5f}   {first + ito:8.5f}")
```

它的输出。

```
W_1^3 = 13.21623
   steps     sum 3W^2 dW    + sum 3W dt    total
      64         9.93773         3.81400   13.75173
     256         9.55822         3.87489   13.43311
    1024         9.35323         3.88797   13.24120
    4096         9.45031         3.88991   13.34021
   16384         9.29872         3.89070   13.18942
   65536         9.32862         3.89080   13.21942
  262144         9.33020         3.89085   13.22105
```

读输出。 这条路径终点很高（$W_1^3 = 13.2162$）。伊藤项 $\sum 3W\,\Delta t$ 很大，稳定得很快（它是普通积分）；随机和 $\sum 3W^2\Delta W$ 在稳定之前游移得更多。两者之和逼近 W_1^3；没有伊藤项，它会差大约 $\int_0^1 3W_t\,dt$，在这条路径上接近 4。

练习 16.8

用伊藤引理推出的两个期望，由模拟验证。

```
Z = rng.standard_normal(1_000_000)
for t in (0.5, 1.0, 2.0):
    Wt = math.sqrt(t) * Z                       # W_t has the distribution of sqrt(t) Z
    print(f"t = {t}: E[cos W_t] = {np.cos(Wt).mean():.4f} (e^(-t/2) = {math.exp(-t /
2):.4f}), "
          f"E[W_t^4] = {(Wt**4).mean():.4f} (3t^2 = {3 * t * t:.4f})")
```

它的输出。

```
t = 0.5: E[cos W_t] = 0.7788 (e^(-t/2) = 0.7788), E[W_t^4] = 0.7492 (3t^2 = 0.7500)
t = 1.0: E[cos W_t] = 0.6065 (e^(-t/2) = 0.6065), E[W_t^4] = 2.9966 (3t^2 = 3.0000)
t = 2.0: E[cos W_t] = 0.3677 (e^(-t/2) = 0.3679), E[W_t^4] = 11.9864 (3t^2 = 12.0000)
```

读输出。两个公式都是不借助任何密度推出的，与模拟相符到小数点后三四位。

自测

1. $d(W^2) = 2W\,dW + dt$。其中的 dt 是 $\frac{1}{2}f''(dW)^2 = \frac{1}{2}\cdot 2\cdot dt$：泰勒展开的二阶项，因为 $(dW)^2 = dt$ 而保留下来。

2. 高出 $\frac{1}{2}\sigma^2 = 0.02$，即每年 2%。

3. $b^2\,dt$。

第 17 课解答

几何布朗运动

练习 17.1 至 17.8 以及第 17 课自测题的解答。

练习 17.1

思路。 对 $\ln S$ 用伊藤引理；各处的 S 相互抵消，剩下常数。

第 1 步。 $f(S)=\ln S$：$f'=1/S$，$f''=-1/S^2$，$f_t=0$。

第 2 步。 输入 $dS=\mu S\,dt+\sigma S\,dW$，所以 $(dS)^2=\sigma^2S^2\,dt$。于是

$$d\ln S=\frac{1}{S}\,dS-\frac{1}{2S^2}(dS)^2=\mu\,dt+\sigma\,dW-\tfrac12\sigma^2\,dt=\left(\mu-\tfrac12\sigma^2\right)dt+\sigma\,dW.$$

第 3 步。 积分：$\ln S_t=\ln S_0+(\mu-\frac12\sigma^2)t+\sigma W_t$。

第 4 步。 取指数：$S_t=S_0e^{(\mu-\frac12\sigma^2)t+\sigma W_t}$。

练习 17.2

思路。 用二元伊藤引理对候选解求微分，再作比较。

取 $f(t,w)=S_0e^{(\mu-\frac12\sigma^2)t+\sigma w}$：$f_t=(\mu-\frac12\sigma^2)f$，$f_w=\sigma f$，$f_{ww}=\sigma^2f$。输入 W（$a=0$，$b=1$）：

$$dS=\left((\mu-\tfrac12\sigma^2)S+\tfrac12\sigma^2S\right)dt+\sigma S\,dW=\mu S\,dt+\sigma S\,dW.$$

√ 并且在 $t=0$ 时取值 S_0，正确。

练习 17.3

思路。 $\ln S_T\sim N(m,s^2)$，其中 $m=\ln S_0+(\mu-\frac12\sigma^2)T$，$s=\sigma\sqrt{T}$；套用第 5 课。

- **均值** $S_0e^{\mu T}=103.0455$。
- **中位数** $e^m=S_0e^{(\mu-\frac12\sigma^2)T}=101.0050$。

- **众数** $e^{m-s^2} = S_0 e^{(\mu - \frac{3}{2}\sigma^2)T} = 97.0446$。

$P(S_T > E[S_T])$。 $S_T > S_0 e^{\mu T} \iff (\mu - \frac{1}{2}\sigma^2)T + \sigma W_T > \mu T \iff W_T > \frac{1}{2}\sigma T \iff Z > \frac{1}{2}\sigma\sqrt{T}$。所以概率为 $N(-\frac{1}{2}\sigma\sqrt{T}) = N(-0.1) = 0.4602$。

为什么小于一半。 对数正态分布向右偏斜：罕见的极高结果把均值拉到中位数之上。均值位于分布的中间之上，所以位于它之上的概率不到一半。

练习 17.4

思路。 对 S^2 用伊藤引理，得到关于其均值的微分方程。

第 1 步。 $d(S^2) = 2S\,dS + (dS)^2 = (2\mu + \sigma^2)S^2\,dt + 2\sigma S^2\,dW$。

第 2 步。 $m(t) = E[S_t^2]$：$m' = (2\mu + \sigma^2)m$，$m(0) = S_0^2$，所以 $m(T) = S_0^2 e^{(2\mu+\sigma^2)T} = 11051.71$（增长率 0.10）。

第 3 步。 $\mathrm{Var}(S_T) = S_0^2 e^{(2\mu+\sigma^2)T} - S_0^2 e^{2\mu T} = S_0^2 e^{2\mu T}(e^{\sigma^2 T} - 1) = 433.34$，标准差为 20.82。这就是第 5 课的公式（那里用 r 代替 μ）。

练习 17.5

思路。 它是 S_0 乘以指数鞅。

$e^{-\mu t} S_t = S_0 e^{(\mu - \frac{1}{2}\sigma^2)t - \mu t + \sigma W_t} = S_0 e^{\sigma W_t - \frac{1}{2}\sigma^2 t}$，是鞅（第 13 课）。

当 $\mu = r$ 时： $e^{-rt}S_t$ 是鞅：贴现股价是一场公平游戏，这正是风险中性世界的定义性质（第 11、13 课）。

练习 17.6

思路。 对数收益率是正态的；标准化即可。

$\ln(S_T/S_0) \sim N\big((\mu - \frac{1}{2}\sigma^2)T,\ \sigma^2 T\big)$：这里均值为 0.01，标准差为 0.2。

- $P(S_1 < 100) = P(\ln(S_1/S_0) < 0) = N\big((0 - 0.01)/0.2\big) = N(-0.05) = 0.4801$。
- $P(S_1 < 80) = N\big((\ln 0.8 - 0.01)/0.2\big) = N\big((-0.2231 - 0.01)/0.2\big) = N(-1.1657) = 0.1219$。

练习 17.7

欧拉法的强误差与弱误差，与精确解使用同样的噪声。

```
import numpy as np

rng = np.random.default_rng(177)
paths, fine = 20_000, 1024
dW = rng.normal(0, math.sqrt(T / fine), (paths, fine))
exact = S0 * np.exp((mu - 0.5 * sigma**2) * T + sigma * dW.sum(axis=1))
print("   steps   strong error   weak error")
for n in (4, 16, 64, 256, 1024):
    dWn = dW.reshape(paths, n, fine // n).sum(axis=2)             # the same noise, n coarser
steps
    euler = S0 * np.prod(1 + mu * T / n + sigma * dWn, axis=1)
    strong = np.abs(euler - exact).mean()
    weak = abs(euler.mean() - exact.mean())                       # same paths, so the
sampling noise cancels
    print(f"{n:8d}   {strong:12.4f}   {weak:10.4f}")
```

它的输出。

```
   steps   strong error   weak error
       4         1.1223       0.0176
      16         0.5728       0.0075
      64         0.2904       0.0029
     256         0.1441       0.0023
    1024         0.0719       0.0002
```

读输出。 n 每乘以 4，强误差就减半：它像 $n^{-1/2}$ 那样缩小。弱误差缩小得更快，大约像 n^{-1}，但在 20,000 条路径上它小到在后面几行中能看出抽样噪声。（正文改为由 $E[S_T^{\text{Euler}}] = S_0(1+\mu T/n)^n$ 精确计算弱误差，避开了噪声。）

练习 17.8

Milstein 格式与欧拉法对比。

```
print("   steps   Euler strong   Milstein strong")
for n in (4, 16, 64, 256, 1024):
    dWn = dW.reshape(paths, n, fine // n).sum(axis=2)
    h = T / n
    euler = S0 * np.prod(1 + mu * h + sigma * dWn, axis=1)
    milstein = S0 * np.prod(1 + mu * h + sigma * dWn + 0.5 * sigma**2 * (dWn**2 - h), axis=1)
    print(f"{n:8d}   {np.abs(euler - exact).mean():12.4f}   {np.abs(milstein -
exact).mean():15.5f}")
```

它的输出。

```
   steps   Euler strong   Milstein strong
       4         1.1223           0.12029
      16         0.5728           0.03362
      64         0.2904           0.00873
     256         0.1441           0.00220
    1024         0.0719           0.00055
```

读输出。 n 每乘以 4，Milstein 格式的强误差大约缩小到四分之一（256 步与 1024 步之比为 3.99）：强阶为 1，而欧拉法为 ½。多出来的一项 $\frac{1}{2}\sigma^2(\Delta W^2 - \Delta t)$ 恰好是欧拉法丢掉的精确增长因子中的那一部分（第 17 课最后一节）。用 1024 步时，逐条路径地看，Milstein 格式的精度高出 100 倍以上。

自测

1. $\mu - \frac{1}{2}\sigma^2 = 0.01$：每年 1%。

2. 对数正态分布向右偏斜：少数极高的结果把均值拉高，高于中位数。

3. 强误差缩小约 $\sqrt{2}$ 倍（到约 71%）；弱误差缩小约 2 倍（到约 50%）。

第 18 课解答

伊藤工具箱

练习 18.1 至 18.8 以及第 18 课自测题的解答。

练习 18.1

思路。 用伊藤引理，然后只看 dt 项。

过程	伊藤引理	DT 项	是鞅吗?
W^3	$3W^2\,dW + 3W\,dt$	$3W$	否
$W^3 - 3tW$	$3(W^2 - t)\,dW$	0	是
e^W	$e^W\,dW + \tfrac{1}{2}e^W\,dt$	$\tfrac{1}{2}e^W$	否
$e^{W - t/2}$	$e^{W-t/2}\,dW$	0	是
tW	$W\,dt + t\,dW$	W	否

对 $W^3 - 3tW$：$-3tW$ 这一项满足 $d(tW) = W\,dt + t\,dW$（乘积法则），所以它的 $-3W\,dt$ 抵消了来自 W^3 的 $3W\,dt$。对 $e^{W-t/2}$：时间导数给出 $-\tfrac{1}{2}e^{W-t/2}\,dt$，它抵消了伊藤项 $+\tfrac{1}{2}e^{W-t/2}\,dt$。

练习 18.2

思路。 指数中的 $-ct$ 必须抵消曲率项 $\tfrac{1}{2}\theta^2$。

取 $f(t, w) = e^{\theta w - ct}$：$f_t = -cf$，$f_{ww} = \theta^2 f$，所以 dt 项为 $(-c + \tfrac{1}{2}\theta^2)f$。当 $c = \tfrac{1}{2}\theta^2$ 时它消失。对 $\theta = 2$：$c = 2$。

练习 18.3

思路。 有一个光滑因子的乘积法则。

第 1 步。 $X = t$（$dX = dt$，没有 dW），$Y = W$：$d(tW) = t\,dW + W\,dt + dt\,dW = t\,dW + W\,dt$。

第 2 步。 积分：$tW_t = \int_0^t s\,dW_s + \int_0^t W_s\,ds$，所以 $tW_t - \int_0^t W_s\,ds = \int_0^t s\,dW_s$，是一个伊藤积分：鞅（等价地，$d(tW - \int W) = t\,dW$，没有 dt 项）。

第 3 步。 它的均值为 0，所以 $E[1 \cdot W_1] = E\int_0^1 W_s\,ds$，而 $E[W_1] = 0$。因此 $E\int_0^1 W_s\,ds = 0$。

练习 18.4

思路。 合并 dt 项；它们相互抵消。然后取期望。

$d(W^4) = 4W^3\,dW + 6W^2\,dt$；$d(tW^2) = W^2\,dt + t(2W\,dW + dt)$；
$d(3t^2) = 6t\,dt$。所以

$$\begin{aligned} d(W^4 - 6tW^2 + 3t^2) &= 4W^3\,dW + 6W^2\,dt - 6W^2\,dt - 12tW\,dW - 6t\,dt + 6t\,dt \\ &= (4W^3 - 12tW)\,dW. \end{aligned}$$

没有 dt 项：是一个从 0 出发的鞅。所以 $E[W_t^4] - 6tE[W_t^2] + 3t^2 = 0$，得到 $E[W_t^4] = 6t^2 - 3t^2 = 3t^2$。

练习 18.5

思路。 每个因子都是指数鞅；乘积法则中的交叉项取决于相关系数。

第 1 步。 $dX = X\,dW$，$dY = Y\,dB$（第 18 课：没有 dt 项）。

第 2 步。 $d(XY) = X\,dY + Y\,dX + dX\,dY = XY\,dB + XY\,dW + XY\,dW\,dB$。

独立时： $dW\,dB = 0$，所以 $d(XY) = XY(dW + dB)$：没有 dt 项，是鞅。

相关系数为 ρ 时： $dW\,dB = \rho\,dt$，所以 $d(XY) = \rho XY\,dt + XY(dW + dB)$：有一个漂移 ρXY。这时 XY 不是鞅（对 $\rho \neq 0$），但 $e^{-\rho t}XY$ 是。相关的指数平均而言相互增强。

练习 18.6

思路。 与贴现因子（光滑，没有 dW）的乘积法则。

$d(e^{-rt}S) = e^{-rt}\,dS - re^{-rt}S\,dt = (\mu - r)e^{-rt}S\,dt + \sigma e^{-rt}S\,dW$。只有当 $\mu = r$ 时 dt 项才消失。

当 $\mu = 8\%$ 时： $E[e^{-r}S_1] = e^{-r}S_0e^{\mu} = 100e^{0.05} = 105.1271$：高于 100，是下鞅。预期股票每年胜过现金 5%。

练习 18.7

对 W³ 和 W³ − 3tW 分组进行鞅检验。

```
import numpy as np

rng = np.random.default_rng(187)
n = 400_000
W_h = rng.normal(0, math.sqrt(0.5), n)                    # W_0.5
W_1 = W_h + rng.normal(0, math.sqrt(0.5), n)              # W_1 = W_0.5 + an independent step
edges = np.quantile(W_h, np.linspace(0, 1, 6))
group = np.clip(np.digitize(W_h, edges[1:-1]), 0, 4)      # five groups by W_0.5
print("group   mean W_0.5   gap for W^3   gap for W^3 - 3tW")
for k in range(5):
    s = group == k
    gap_a = (W_1[s] ** 3).mean() - (W_h[s] ** 3).mean()
    gap_b = (W_1[s] ** 3 - 3 * W_1[s]).mean() - (W_h[s] ** 3 - 1.5 * W_h[s]).mean()
    print(f"{k + 1:5d}   {W_h[s].mean():10.3f}   {gap_a:11.3f}   {gap_b:17.3f}")
```

它的输出。

```
group   mean W_0.5   gap for W^3   gap for W^3 - 3tW
    1       -0.990        -1.469               0.012
    2       -0.374        -0.567              -0.007
    3        0.002         0.007               0.009
    4        0.377         0.546               0.001
    5        0.991         1.504               0.004
```

读输出。 对 W^3，每组的差距约为 $1.5\times$（该组的 $W_{0.5}$）：对在时刻 0.5 处于低位的路径为负，对处于高位的为正。这就是积分后的漂移，$E[\int_{0.5}^{1} 3W_t\,dt \mid W_{0.5}] = 3W_{0.5} \times 0.5$。这些差距在所有组上平均后相互抵消，这就是为什么 $E[W^3]$ 保持为 0，而 W^3 却不是鞅。对 $W^3 - 3tW$，每个差距都是噪声。

练习 18.8

用 Z 重新加权使 W 平移 θT。

```
theta, T = 0.5, 1.0
WT = rng.normal(0, math.sqrt(T), 1_000_000)
Z = np.exp(theta * WT - 0.5 * theta**2 * T)
for a in (0.0, 0.5, 1.0):
    lhs = (Z * (WT > a)).mean()
    rhs = 1 - Ncdf((a - theta * T) / math.sqrt(T))       # P(W_T + theta T > a)
    print(f"a = {a}: E[Z 1(W_T > a)] = {lhs:.4f},  P(W_T + theta T > a) = {rhs:.4f},  P(W_T >
a) = {1 - Ncdf(a):.4f}")
```

它的输出。

```
a = 0.0: E[Z 1(W_T > a)] = 0.6911,  P(W_T + theta T > a) = 0.6915,  P(W_T > a) = 0.5000
a = 0.5: E[Z 1(W_T > a)] = 0.4994,  P(W_T + theta T > a) = 0.5000,  P(W_T > a) = 0.3085
a = 1.0: E[Z 1(W_T > a)] = 0.3083,  P(W_T + theta T > a) = 0.3085,  P(W_T > a) = 0.1587
```

读输出。 在每种情形下，加权后的概率都与平移后变量 $W_T + \theta T$ 的概率相符，而不是与原变量的概率相符。这是 Girsanov 定理在一个时刻上的形式；第 25 课把它推广到整条路径。

自测

1. $c = \frac{1}{2} \times 0.3^2 = 0.045$。

2. 它的 dt 项是 $3W\,dt$：给定路径所在位置，它未来的平均值不等于当前值（$W > 0$ 时更高，$W < 0$ 时更低）。这些效应总体上相互抵消，所以它的无条件均值保持为 0，但鞅需要的是条件意义下的命题。

3. $d(XY) = X\,dY + Y\,dX$：当 X 没有 dW 部分时，交叉项 $dX\,dY$ 为 0。